

# Técnica de Deep Learning para Previsão da Carga de Energia Elétrica no Sistema Brasileiro

Vinicius Rogério da Silva  
Departamento de Informática  
Pontifícia Universidade Católica do Rio de Janeiro  
Rio de Janeiro, RJ 22451-900  
vsilva@inf.puc-rio.br

**Abstract**—A demanda de energia elétrica em um sistema possui características de tendência e sazonalidade, podendo ser influenciada por diversas outras variáveis, como temperatura e fatores socioeconômicos, por exemplo. Conhecer esse comportamento e ser capaz de prevê-lo para o futuro é fundamental para que a geração de energia esteja alinhada com a demanda esperada. Nesse contexto, dada a característica temporal desses dados, diversas abordagens podem ser aplicadas, desde técnicas estatísticas tradicionais para análise de séries temporais, até modelos computacionais mais complexos, como as variações de Redes Neurais Artificiais (RNA). O presente trabalho propõe a aplicação de um modelo LSTM (Long Short-Term Memory), um tipo de RNA recorrente, para a previsão da carga de energia elétrica no Sistema Interligado Nacional (SIN) do Brasil. Utilizando uma abordagem univariada, o modelo demonstrou ser promissor, apresentando um MAPE inferior a 2% e sendo capaz de prever novas observações com base em 60 dias de dados históricos.

## I. INTRODUÇÃO

O Sistema Interligado Nacional – SIN corresponde à rede de produção e transmissão de energia elétrica no território nacional, sendo dividido em quatro subsistemas principais: Norte, Nordeste, Sudeste/Centro-Oeste e Sul. É composto predominantemente por usinas hidrelétricas, embora também existam instalações de usinas eólicas e térmicas [1]. Até 2023, eram mais de 171 mil km de linhas de transmissão, número que deve ultrapassar os 200 mil km até 2028 [2].

Toda essa estrutura integrada entre regiões é operada pelo ONS – Operador Nacional do Sistema Elétrico, entidade responsável pelo planejamento, coordenação e controle da operação dessas instalações, e que é regulada e fiscalizada pela ANEEL – Agência Nacional de Energia Elétrica. O ONS também cuida de diversas iniciativas e estudos para melhor entender a dinâmica da operação e garantir menor custo e maior eficiência para o sistema como um todo [3]. Nesse contexto, a previsão da carga de energia elétrica é um tópico de interesse e com potencial de contribuição na gestão eficiente desses recursos, podendo impactar entidades públicas e privadas, além dos consumidores finais.

### A. Carga em Sistemas Elétricos

A carga pode ser entendida como a quantidade de energia elétrica que é demandada por um sistema em um determinado período de tempo. No entanto, é de se imaginar que, por conta da natureza complexa do sistema e das linhas de transmissão,




Fig. 1. Dados diários de carga de energia elétrica no SIN, em MWmed, de 2016 a 2024. Fonte: ONS.

perdas sempre ocorrem durante o processo, significando que nem toda a energia gerada chega de fato ao consumidor final. O cálculo da carga que é realizado pelo ONS já considera tais perdas, e por isso entende-se que o consumo de energia elétrica no país é sempre um pouco menor do que a carga. Tendo essa diferenciação em mente, a demanda representada pela carga possui estreita ligação com o consumo que efetivamente ocorre, e portanto representa a quantidade de energia que será “injetada” na rede para atender aos consumidores [4].

### B. Fonte de dados

O ONS disponibiliza, em seu próprio site, uma base de dados contendo o histórico de carga de energia dos últimos anos. É possível extrair dados com granularidade diária, mensal, anual ou de semana operativa, além de ser possível dividir por cada um dos 4 subsistemas [5].

No contexto deste trabalho, foram coletados os dados de carga diários, para todos os dias a partir de 01/01/2016, até o dia 30/04/2024, e considerando todos os subsistemas. Ou seja, a carga para a qual deseja-se realizar a previsão é a de todo o SIN. A unidade de medida utilizada é a de MWmed, que é a carga média observada, em megawatts, em cada dia considerado. A Figura 1 apresenta uma visão desse dado ao longo de todo o período coletado. Mesmo numa inspeção visual inicial, já é possível identificar a característica sazonal relacionada aos períodos mais quentes e mais frios do ano no país, além de uma tendência de crescimento que se acentuou a partir de 2020.

## II. TRABALHOS RELACIONADOS

Nesta seção é realizada uma breve revisão da bibliografia existente relacionada ao tema. Parte desses trabalhos não necessariamente se refere a previsões de carga, mas sim de outras variáveis que também representam um grande interesse para o setor elétrico brasileiro e de demais países.

O trabalho de UGURLU et al., 2018 [6] focou na previsão de preços de energia elétrica no mercado da Turquia. Além dos preços históricos, também foram consideradas outras variáveis exógenas, como demanda e geração de energia e a temperatura em cada período. A técnica de LSTM esteve entre as que foram testadas no estudo, tendo apresentado o segundo melhor desempenho na tarefa proposta, ficando atrás apenas de GRUs - Gated Recurrent Units, outro tipo de Redes Neurais Recorrentes. Segundo os autores, um dos motivos pelos quais a GRU mostrou melhor desempenho é o fato de que necessita de menos parâmetros em seu treinamento, quando comparada ao LSTM. A GRU também mostrou desempenho melhor que outros métodos estatísticos considerados estado da arte. Vale ressaltar que os autores utilizaram 300 épocas para o treinamento das redes neurais, um número 3 vezes maior do que o utilizado no presente trabalho.

NEVES, 2008 [7] adotou uma abordagem baseada em um modelo polinomial do tipo ZIP - impedância constante (Z), corrente constante (I) e potência constante (P), e em um modelo exponencial para determinação da carga em sistemas fechados. É realizada a suposição de normalidade para as medidas envolvidas, de modo que a função de densidade de probabilidade é escrita em termos dos parâmetros de carga. Essencialmente, trata-se de um problema de otimização em que o interesse é encontrar parâmetros ideais que maximizem essa função. Os resultados mostraram que tanto o modelo ZIP como o exponencial se aproximaram de forma satisfatória das curvas reais de carga.

Em EYISI & LOTFIFARD, 2021 [8], o objetivo foi obter curvas de carga através de uma técnica conhecida como ANFIS - Adaptive Neuro Fuzzy Inference System, que é um tipo de RNA que utiliza lógica *fuzzy* em sua primeira camada para converter valores numéricos em valores *fuzzy*, que acabam por substituir o uso de uma função de ativação sigmóide, por exemplo. Foram utilizadas como features a carga atual, a carga 24h antes e a carga 1 semana antes (no mesmo horário), referentes a um sistema de distribuição de 11kV. Os modelos obtidos mostraram MAPEs entre 2% e 4%.

Por fim, o trabalho de GRIGORAS et al., 2012 [9] adota uma abordagem de cluterização para determinar perfis de carga em um sistema de distribuição da Romênia. O algoritmo utilizado foi o K-means, um dos mais conhecidos em tarefas de clusterização. No caso do estudo, foi escolhido um número ótimo de clusters com K=3, através da métrica de *silhouette*. É válido ressaltar que o uso do K-means se deu para a definição de grupos (ou perfis) de carga com base em suas características. No entanto, as estimativas propriamente ditas foram feitas através de uma equação que envolve o número de clusters, a média de consumo em cada cluster e outros fatores do sistema. Ao final, o modelo obtido mostrou um erro relativo em torno de 2.35%.

De modo geral, parece existir um padrão entre boa parte dos trabalhos encontrados na bibliografia, em que técnicas de aprendizado de máquina e/ou aprendizado profundo são combinadas com conhecimento mais aprofundado de engenharia e física para a estimação da carga.




Fig. 2. Representação simplificada das componentes de um neurônio artificial. Fonte: elaboração própria.

### III. TÉCNICA PROPOSTA

#### A. Redes Neurais Artificiais

Em termos gerais, Redes Neurais Artificiais (RNA) são modelos que se inspiram no funcionamento dos neurônios humanos e suas conexões para aprender padrões a partir de dados previamente fornecidos. Uma vez aprendidos, tais padrões podem ser utilizados para prever uma variável de interesse para valores antes não vistos. Um neurônio artificial é composto por:

- uma entrada, que recebe dados externos  $(x_1, x_2, \dots, x_n)$ ;
- um conjunto de pesos, que ponderam cada um dos seus respectivos valores de entrada  $(w_1, w_2, \dots, w_n)$ ;
- um combinador linear, que agrega os sinais de entrada já ponderados ( $\Sigma$ );
- um viés (ou limiar)  $\theta$  de ativação, que determina um valor apropriado para o disparo do neurônio;
- o potencial de ativação  $u$ , dado por

$$u = \sum_{i=1}^n w_i x_i - \theta;$$

- uma função de ativação  $g$ , que limita a saída do neurônio dentro de um intervalo de valores razoáveis. Comumente é utilizada a função sigmóide, dada por

$$g(\cdot) = \frac{1}{1 + e^{-x}};$$

- e, por fim, o valor de saída do neurônio,  $y = g(u)$ .

A Figura 2 ilustra um neurônio artificial simplificado. Ao combinar múltiplas camadas de neurônios com diferentes tamanhos de entrada e diversas outras funções de ativação, as possibilidades de arquiteturas resultantes são infinitas. Na prática, algumas arquiteturas se tornaram mais famosas devido ao seu bom desempenho em tarefas específicas, e por isso são replicadas com maior facilidade.

#### B. LSTM - Long Short-Term Memory

A LSTM (Long Short-Term Memory) é um tipo de rede neural recorrente (RNN) capaz de lidar com dados sequenciais, como frases ou séries temporais. A ideia desse tipo de rede é utilizar uma arquitetura baseada em "portões" que controlam o fluxo de informações passadas para camadas posteriores, de modo a manter uma "lembrança" a respeito de observações que vieram muito tempo atrás. Por meio dessa abordagem, as



Modelo	Time Steps	Batch Size
Model1	90	64
Model2	90	32
Model3	60	64
Model4	60	32
Model5	30	64
Model6	30	32

TABLE I  
CONFIGURAÇÕES DOS MODELOS

Model	MAE	MAPE
Model1	1779.60	2.33%
Model2	1478.09	1.99%
Model3	1570.52	2.1%
<b>Model4</b>	<b>1441.23</b>	<b>1.95%</b>
Model5	1653.74	2.21%
Model6	1797.96	2.4%

TABLE II  
DESEMPENHO DOS MODELOS




Fig. 4. Model1 - Previsões de janeiro a abril de 2024.




Fig. 5. Model2 - Previsões de janeiro a abril de 2024.

Conforme resumido na Tabela I, os modelos gerados se referem às combinações entre *timesteps* de 90, 60 e 30 dias, com *batch sizes* 64 ou 32. Os conjuntos de treino e teste também foram gerados de forma individualizada para cada um dos modelos, visto que o tamanho das *time steps* influencia diretamente a magnitude desses *datasets*.

Após o treinamento, cada modelo foi utilizado para realizar previsões em seu respectivo conjunto de teste, de modo que as métricas de MAE e MAPE foram calculadas e se encontram resumidas na Tabela II. Conforme esses resultados, o Model4 foi aquele que mostrou melhor desempenho preditivo, gerando um MAE de aprox. 1441 MWmed, o que representou um MAPE de 1.95%.




Fig. 6. Model3 - Previsões de janeiro a abril de 2024.




Fig. 7. Model4 - Previsões de janeiro a abril de 2024.




Fig. 8. Model5 - Previsões de janeiro a abril de 2024.





Fig. 9. Model6 - Previsões de janeiro a abril de 2024.



Apenas para fins comparativos, as previsões de 01/01/2024 a 30/04/2024 foram exibidas para todos os modelos, da Figura 4 à Figura 9. Nelas é possível observar o comportamento mais ajustado do Model4 em comparação aos demais modelos, que em alguns momentos subestimam ou superestimam os valores de carga. Apesar disso, é válido comentar que os MAPEs para todos os demais modelos não passaram de 2.4%, o que ainda é um erro consideravelmente baixo, e que está na mesma dimensão dos erros observados na bibliografia para trabalhos semelhantes.

## V. CONCLUSÃO E TRABALHOS FUTUROS

Neste estudo, foi proposta a aplicação de um modelo Long Short-Term Memory (LSTM) para a previsão da carga de energia elétrica no SIN, o Sistema Interligado Nacional do Brasil. Os dados foram coletados na plataforma aberta do ONS – Operador Nacional do Sistema Elétrico, e contém a carga de energia desde 01/01/2016 até 30/04/2024 para todo o sistema. Em cada uma das configurações testadas, 80% dos dados foram separados para treinamento e 20% para o teste dos modelos. Ao todo, 6 modelos foram experimentadas e comparados, tendo o melhor deles mostrado um MAE de 1441 MWmed e MAPE de 1.95% (Model4). Este modelo utilizou um *batch* de tamanho 32 e um *timestep* igual a 60, o que significa que ele utiliza 60 dias passados para prever um dia futuro. Assim sendo, uma vez já treinado, no mínimo dois meses de novos dados se fazem necessários para prever novas observações.

Modelos com essa característica podem ser empregados para otimizar a geração de energia em sistemas elétricos complexos, como é o caso do SIN; ou mesmo em sistemas fechados menores, garantindo maior previsibilidade dos níveis de operação e da demanda de energia esperada. Dado esse potencial, trabalhos futuros poderiam mergulhar ainda mais nessa técnica, explorando outros aspectos da arquitetura, como o aumento do número de camadas LSTM e a variação do número de *units* em cada camada. Outra possibilidade seria a aplicação de GRUs – Gated Recurrent Units, conforme feito em [6], dado seu ótimo poder preditivo em dados de séries temporais (em muitos casos, superior ao das LSTM). Numa linha comparativa, ajustes de modelos estatísticos tradicionais poderiam ser realizados, para verificar o ganho (ou perda) que existe em se aplicar uma abordagem baseada em Redes Neurais. Por fim, outro interesse se concentra na adição de mais variáveis explicativas ao modelo, como por exemplo a temperatura média (ou mínima e máxima) de cada dia, indicadores macroeconômicos como o IPCA, dentre outras, verificando se são capazes de contribuir ou não para a diminuição do erro do modelo.

## REFERENCES

- [1] Operador Nacional do Sistema Elétrico, “O que é o sin?” <https://www.ons.org.br/paginas/sobre-o-sin/o-que-e-o-sin>, 2024, acesso em: 01 jun. 2024.
- [2] —, “O sistema em números.” <https://www.ons.org.br/paginas/sobre-o-sin/o-sistema-em-numeros>, 2024, acesso em: 01 jun. 2024.
- [3] —, “O que é o ons?” <https://www.ons.org.br/paginas/sobre-o-ons/o-que-e-ons>, 2024, acesso em: 01 jun. 2024.
- [4] MegaWhat, “Carga.” <https://megawhat.energy/verbetes/272/carga>, 2022, acesso em: 06 jun. 2024.
- [5] Operador Nacional do Sistema Elétrico, “Carga de energia.” [https://www.ons.org.br/Paginas/resultados-da-operacao/historico-da-operacao/carga\\_energia.aspx](https://www.ons.org.br/Paginas/resultados-da-operacao/historico-da-operacao/carga_energia.aspx), 2024, acesso em: 01 jun. 2024.
- [6] U. Ugurlu, I. Oksuz, and O. Tas, “Electricity price forecasting using recurrent neural networks,” *Energies*, vol. 11, no. 5, 2018. [Online]. Available: <https://www.mdpi.com/1996-1073/11/5/1255>
- [7] M. S. Neves, “Modelagem de carga em sistemas de energia elétrica: modelo matemático e sua validação com testes de campo,” *M. Sc., UFJF, Juiz de Fora, MG*, 2008.
- [8] C. Eyisi and S. Lotfifard, “Load estimation for electric power distribution networks,” 09 2021.
- [9] G. Grigoraş, F. Scarlatache, and G. Cârţină, “Load estimation for distribution systems using clustering techniques,” in *2012 13th International Conference on Optimization of Electrical and Electronic Equipment (OPTIM)*, 2012, pp. 301–306.
- [10] F. Pedregosa, G. Varoquaux, A. Gramfort, V. Michel, B. Thirion, O. Grisel, M. Blondel, P. Prettenhofer, R. Weiss, V. Dubourg, J. Vanderplas, A. Passos, D. Cournapeau, M. Brucher, M. Perrot, and E. Duchesnay, “Scikit-learn: Machine learning in Python,” *Journal of Machine Learning Research*, vol. 12, pp. 2825–2830, 2011.
- [11] M. Abadi, A. Agarwal, P. Barham, E. Brevdo, Z. Chen, C. Citro, G. S. Corrado, A. Davis, J. Dean, M. Devin, S. Ghemawat, I. Goodfellow, A. Harp, G. Irving, M. Isard, Y. Jia, R. Jozefowicz, L. Kaiser, M. Kudlur, J. Levenberg, D. Mané, R. Monga, S. Moore, D. Murray, C. Olah, M. Schuster, J. Shlens, B. Steiner, I. Sutskever, K. Talwar, P. Tucker, V. Vanhoucke, V. Vasudevan, F. Viégas, O. Vinyals, P. Warden, M. Wattenberg, M. Wicke, Y. Yu, and X. Zheng, “TensorFlow: Large-scale machine learning on heterogeneous systems,” 2015, software available from tensorflow.org. [Online]. Available: <https://www.tensorflow.org/>